Preparación de los datos: qué hice y por qué

1. Qué hice

- Subí los 12 CSV mensuales a Drive y trabajé en Google Colab, celda por celda, para que quede todo documentado y lo puedan ver.
- Revisé las 79 columnas y los datos faltantes de cada mes. Las columnas esenciales están completas.
- Dejé **una fila por orden**: en los archivos cada fila es un ítem, y el monto de la orden se repite en cada uno.
- Revisé y corregí errores en los montos, y marqué lo que no se puede corregir.
- Generé los archivos para el clúster: órdenes limpias, una muestra de prueba y las aristas del grafo organismo→proveedor.

2. Por qué lo hice

- **Formato:** los textos traen saltos de línea dentro de comillas, y Pig y Hadoop leen línea por línea. Con los CSV crudos las filas se rompen.
- **Conteo:** sumar el monto fila por fila contaría varias veces las órdenes con más ítems.
- **Montos:** 12 órdenes en UTM/UF con montos absurdos sumaban el 59 % del monto total. Sin corregirlas, el ranking por monto y el PageRank medirían errores de digitación.
- **Grafo:** Giraph necesita aristas en formato de dos columnas, como en el Lab 8, y los datos originales no las traen.

3. Qué quedó al final

Cifra	Valor
Líneas (ítems) en los 12 archivos	5.141.167 (todas leídas sin errores)
Órdenes distintas	1.856.038 (ninguna repetida entre meses)
Órdenes que se usan en los rankings	1.853.390 · 75.600 proveedores · 1.165 organismos
Aristas organismo→proveedor	476.703
Monto total sin limpiar → limpio	45,80 → 18,18 billones de pesos
Montos corregidos / sospechosos / simbólicos	45 / 21 / 3.004 órdenes

Reglas que apliqué (nada se borra, solo se marca): si la cabecera dice UTM, UF o USD pero los ítems están en pesos, se usa el monto de la cabecera; una orden en otra moneda sobre 10.000 millones de pesos es sospechosa y no suma monto; las de 100 pesos o menos son simbólicas; se excluye el estado «Cancelacion solicitada»; el proveedor se identifica por su código (o su RUT si falta).

Nota: el total de líneas es 66 menos que el 5.141.233 que anotamos en la propuesta. Lo verifiqué con dos métodos distintos sobre los archivos de Drive; propongo que confirmemos cómo se contó antes.

4. Por qué esto nos sirve para lo que sigue

Archivo	Lo usamos para
ordenes_limpias.tsv.bz2	Pig: ranking por monto, por órdenes distintas y por organismos distintos; concentración del gasto; evolución mensual.
ordenes_muestra.tsv	Probar los scripts de Pig en modo local antes de correr los datos completos.
aristas.tsv	Giraph: PageRank sobre el grafo organismo→proveedor (mismo formato del Lab 8).
aristas_muestra.tsv	Probar Giraph rápido antes de la corrida completa.
nodos.tsv	Ponerle nombre a los resultados del PageRank y compararlos con el ranking por monto (los dos perfiles del profesor).

5. Próximos pasos (plazo de ejecución: 16/11)

- Yo subo los archivos al clúster con `scp -P 220` y pasarlos a HDFS (carpeta del grupo).
- Pig: desarrollamos con la muestra en modo local y correr los datos completos en modo clúster, dentro de `screen`.
- Giraph: compilamos el JAR del Lab 8 desde Eclipse, probamos con `pr-ex.tsv` y luego corremos el grafo completo (4 workers).
- Comparo en Colab los resultados del clúster con los de control y armo los dos perfiles: alto monto con bajo PageRank, y bajo monto con alto PageRank.
- Al terminar, borramos los datos sobrantes del clúster, como pidió el profe.